Fatih Kaya

Yazılım Mühendisi

Telefon : 507-571-3033 **Email:** kya.fth10@gmail.com **Medium:** medium.com/@kya.fth10

LinkedIn : linkedin.com/in/kya-fth10 **GitHub:** github.com/fth2745 | github.com/RegenAI25

Yapay Zeka ve Doğal Dil İşleme (NLP/NLU) alanlarında uzmanlaşmış; özellikle Türkçe Büyük Dil Modelleri (LLM) adaptasyonu ve stratejik sektörler (Sağlık, Tarım) için yerli RAG sistemleri geliştirme konusunda uçtan uca deneyime sahip bir Yazılım Mühendisiyim. Yapay zeka odaklı yüksek lisans eğitimim boyunca akademik araştırma ile uygulamalı mühendisliği bir arada yürüttüm; bu süreçte, uluslararası hakemli bir dergide yayımlanan bir çalışmanın öncü yazarı olarak bilimsel araştırma yürütme ve yayın üretme deneyimi edindim. TÜBİTAK 2209-A araştırmacısı ve yapay zeka proje ekibi yöneticisi olarak akademik ve uygulamalı projelerde aktif rol alıyor; DeBERTa, mT5 ve Mistral 7B gibi transformer tabanlı modellerle soru-cevaplama, metin özetleme, RAG tabanlı bilgi erişim ve görsel-metin etkileşimli duygu analizi sistemleri geliştiriyorum. Çok modlu senaryolarda metin ve görsel temsilleri entegre ederek yüksek performanslı, genellenebilir ve ölçeklenebilir modeller tasarlamaya; klasik makine öğrenmesi yöntemlerini modern embedding teknikleriyle birleştirerek çoklu öznitelik füzyonu tabanlı güçlü model mimarileri oluşturmaya odaklanıyorum. Son iki yıldır ise veri kalitesini artırmak amacıyla metin temizleme, tokenizasyon, lemmatizasyon ve öznitelik çıkarımı süreçlerini kapsayan, Türkçe ve İngilizce destekli ölçeklenebilir NLP ön işleme pipeline'ları geliştiriyor; karmaşık ve veri yoğun problemlerde model doğruluğu, sistem verimliliği ve sürdürülebilirliği birlikte optimize eden yapay zeka çözümleri üretiyorum.

YETENEKLER

Programlama & Araçlar: Python, Git , VS Code , Antigravity

Yapay Zeka & Derin Öğrenme Kütüphaneleri: PyTorch, Hugging Face Transformers, FAISS, Scikit-learn, Gradio

Uzmanlık Alanları & Konseptler: Doğal Dil İşleme (NLP/NLU), Bilgisayarlı Görü (Computer Vision), RAG (Retrieval-Augmented Generation), Multi-Modal Fusion, Multi-Task Learning, Derin Öğrenme (Deep Learning)

Modeller & Mimariler: Büyük Dil Modelleri (LLM), Transformer Mimarileri (BERT, T5, Mistral, Qwen)

Veri İşleme & Görselleştirme: Pandas, NumPy, Seaborn, Matplotlib

Diller: Türkçe (Ana Dil), İngilizce (B1 - Orta)

DENEYİM

Zirvedeki Beyinler (Tarım Ve Ormancılık Bakanlığı ile İşbirliği), Ankara - *Veri Analizi Stajyeri*

Temmuz 2024 - Eylül 2024

- Veri analizi süreçlerini otomatikleştirmek için makine öğrenimi algoritmaları entegre ettim; bu kapsamda veri temizleme, zenginleştirme ve tutarsızlıkları tespit edip giderme operasyonlarını bizzat yürüttüm.

EĞİTİM / KURS

Malatya Turgut Özal Üniversitesi, Malatya - *Yazılım Mühendisi*
Eki 2021 - May 2025
3.12/4.0

Malatya Turgut Özal Üniversitesi, Malatya - *Tezli Yüksek Lisans*
Eyl 2025 - Günümüz
3.5/4.0

Roketsan Level UP AI Workshop, Online - *AI Workshop*
Ağustos 2026

ORBİT 3 Bootcamp, Online- *Cloud Eğitimi*
Nisan 2025 - Mayıs 2025

AKADEMİK YAYINLAR

- Kaya, F. ve diğerleri (14 Nisan 2026). "Advancing multimodal emotion analysis: a hybrid deep learning approach with intermediate fusion and multi-task learning". The Visual Computer, Springer. DOI: 10.1007/s00371-026-04475-1.

ÇALIŞMALAR / PROJELER

TÜBİTAK 2209-A

Kullanılan Teknolojiler: Python, PyTorch, Derin Öğrenme (Deep Learning), 1D-CNN, Bi-LSTM, Multi-Head Attention, Sinyal İşleme (ECG/PPG), Veri Mühendisliği, Ranger, CyclicLR, AMP

- VitalDB veri setinden alınan Elektrokardiyogram (ECG) ve Fotopletismografi (PPG) biyosinyallerini kullanarak, invaziv olmayan ve sürekli kan basıncı (Sistolik ve Diyastolik) tahmini yapan hibrit bir derin öğrenme modeli geliştirdim.
- Sinyal morfolojilerini (1D-CNN), tarihsel bağlamı (Bi-LSTM) ve kritik zaman adımlarını (Multi-Head Attention) entegre eden üç aşamalı özgün bir sinyal işleme ve analiz mimarisi kurdum.
- Gürültüye ve hareket artefaktlarına (motion artifacts) karşı modelin dayanıklılığını artırmak amacıyla, basit maksimum/minimum değerler yerine "Yüzdelik Dilim (Percentile)" metoduna dayanan sağlam (robust) bir etiketleme stratejisi uyguladım.
- Model eğitimini PyTorch tabanlı bir altyapıda kodlayarak modüler bir veri analiz kütüphanesi oluşturdum; L1 Loss, Ranger optimizatörü (RAdam + Lookahead), Cyclic Learning Rate ve Automatic Mixed Precision (AMP) teknikleriyle modelin yakınsama hızını ve GPU bellek verimliliğini maksimize ettim.
- Geliştirdiğim model ile Sistolik (MAE: 5.22 mmHg) ve Diyastolik (MAE: 3.23 mmHg) kan basıncı tahminlerinde yüksek doğruluk elde ederek, sistemin uluslararası AAMI (Association for the Advancement of Medical Instrumentation) tıbbi cihaz doğruluk standartlarını başarıyla geçmesini sağladım.

RAG - Türkçe Tıbbi Soru-Cevap Sistemi

Kullanılan Teknolojiler: Python, PyTorch, Hugging Face Transformers, Sentence-Transformers, FAISS, Gradio, Mistral-7B, MS MARCO MiniLM

- Türkçe tıbbi makalelerden oluşan özel bir veri seti üzerinde, bilgi erişimi (Retrieval) ve üretken yapay zeka tabanlı bir Soru-Cevap (QA) sistemi geliştirdim.
- Sentence-Transformers (Retriever), Cross-Encoder MS MARCO MiniLM (Reranker) ve Mistral-7B-Instruct (Generator) adımlarından oluşan uçtan uca bir RAG mimarisi kurdum.
- FAISS kullanarak vektör tabanlı arama altyapısı entegre ettim; L2 normalizasyon ve batch embedding optimizasyonları ile sistemin ölçeklenebilirliğini artırdım.
- Çok dilli embedding modelleri kullanarak Türkçe tıbbi içerik için yüksek doğruluklu bilgi erişimi sağladım ve tekrarlayan/yarım cümleleri filtreleyen özel bir veri işleme hattı (post-processing pipeline) oluşturdum.
- Gradio ile kullanıcıların doğal dilde sorular sorup en alakalı makalelerden üretilmiş cevapları ve ilk 5 kaynak makaleyi görüntüleyebildiği interaktif bir arayüz tasarladım.
- GPU optimizasyonu ve batch işleme teknikleriyle embedding hesaplama süreçlerini hızlandırarak verimliliği artırdım.

Tarım İçin Akıllı Karar Destek Sistemi

Kullanılan Teknolojiler: Python, PyTorch, EfficientNetV2, Qwen3.5, Sentence-Transformers, RAG, Bilgisayarlı Görü (CV), Automatic Mixed Precision (AMP)

- Tarımsal veriler üzerinden bitki hastalıklarını yüksek doğrulukla teşhis eden ve Bilgi Artırımlı Üretim (RAG) mimarisiyle bilimsel tedavi protokolleri sunan karar destek sistemi geliştirdim.
- "Algıdan Reçeteye" (Perception-to-Prescription) iş akışını yönetmek amacıyla hibrit bir mimari kurguladım: Mikro-morfolojik öznitelik çıkarımı için EfficientNetV2 (Fused-MBConv) ve dışsal uzman verisiyle sınırlandırılmış halüsinasyonsuz rapor üretimi için Qwen3.5-9B modellerini entegre ettim.
- Uzun kuyruklu (long-tail) sınıf dengesizliğini gidermek için Sınıf-Farkındalıklı Katmanlı Artırma (CATA) sistemi ile CLAHE, elastik deformasyon ve pHash tabanlı algısal tekilleştirme algoritmaları uyguladım.
- Aşamalı eğitim (Progressive Training) ve Automatic Mixed Precision (AMP) kullanarak modelin yakınsama hızını ve bellek verimliliğini optimize ettim; çıkarım süresini 4.39 ms seviyesine düşürerek gerçek zamanlı operasyonel yeterlilik sağladım.
- Softmax güven skorları üzerinden Temperature Scaling uygulayarak modelin belirsizlik kalibrasyonunu iyileştirdim ve morfolojik olarak birbirine benzeyen hastalıklar (örn. Apple Rust vs. Alternaria) arasındaki ayrım gücünü maksimize ettim.

TR-NER (Türkçe İsim Varlık Tanıma Modeli)

Kullanılan Teknolojiler: Python, PyTorch, umT5, BERT, BiLSTM, Triplet Loss, Seq2Seq, Doğal Dil İşleme (NLP), Çok Görevli Öğrenme (MultiTask Learning)

- Dil bağlamını yüksek doğrulukla çözümlemek üzere BERT tabanlı Transformer ve 2 katmanlı BiLSTM (256 gizli birim) entegrasyonuna sahip Türkçe Named Entity Recognition (NER) modeli geliştirdim.
- Tam bağlantılı katmanlar üzerinden, BIO (Başlangıç, İç, Dış) etiketleme ve varlık türü sınıflandırması için iki bağımsız karar başlığını (head) eşzamanlı olarak eğittim.
- Varlık uzayındaki temsilleri iyileştirmek amacıyla Triplet Loss uyguladım; padding ve geçersiz token'ları dışlamak için maskelenmiş Cross-Entropy (ignore_index=-100) kullanarak dondurulmuş BIO kayıp durumlarını esnek parametrelerle kontrol ettim.
- Automatic Mixed Precision (AMP) ile GPU bellek kullanımını optimize ederek model eğitim süresini önemli ölçüde hızlandırdım.
- Softmax güven skorlarına (confidence threshold) dayalı dinamik etiketleme yaparak düşük güvenilirlikli tahminleri otomatik düzelttim ve "BIO" etiket kuralları gibi algoritmik kontrollerle çıkarım tutarlılığını %100'e yaklaştırdım.
- "O" (dış) etiketini değerlendirme metriklerinden izole ederek, modelin gerçek başarısını doğrudan B ve I etiketleri üzerindeki Precision, Recall ve F1 skorları bazında optimize ettim.

Multi-Modal Görsel-Metin Etkileşimi ile Duygu Analizi

Kullanılan Teknolojiler: Python, PyTorch, NLP, Görüntü İşleme, ResNet-50, ViT, CBAM, RoBERTa, RNN

- Görsel ve metin girdilerini "Intermediate Fusion" tekniği ile birleştiren çok kanallı bir duygu analizi sistemi geliştirdim.
- Görüntü verilerinden ResNet-50, Vision Transformer (ViT) ve CBAM (Convolutional Block Attention Module) kullanarak özellik temsilleri çıkardım; metin verilerinden ise RoBERTa ve BiGRU mimarileri ile bağlamsal temsiller elde ettim.
- Multi-Task Learning (Çok Görevli Öğrenme) yaklaşımıyla hem duygu sınıflandırması hem de duygu yoğunluğu tahminini aynı anda gerçekleştirdim.
- Cross-Entropy kayıp fonksiyonunu (loss) görev bazlı olarak hesaplayıp ağırlıklandırarak model optimizasyonunu sağladım.
- Modelin genellenebilirliğini artırmak için görsellerde yatay çevirme (horizontal flip), döndürme (rotation) ve parlaklık (brightness); metinlerde ise eşanlamlı kelime değişimi (synonym replacement) ve rastgele silme (random deletion) gibi veri artırma (augmentation) teknikleri uyguladım.

Extractive Question Answering (SQuAD v2 Style)

Kullanılan Teknolojiler: Python, PyTorch, AMP (Mixed Precision), SQuAD v2, Transformers

- Transformer tabanlı bir model ile soru-bağlam çiftlerinden cevap konumlarını (start/end) ve cevaplanabilirlik durumunu (Has Answer / No Answer) eşzamanlı olarak tahmin eden bir sistem geliştirdim.
- Modeli SQuAD v2 formatında yapılandırılan veri kümesi ile eğittim ve "[NO_ANS]" etiketli örnekleri özel veri işleme adımlarından geçirdim.
- Eğitim sürecinde Cross-Entropy Loss ve Early Stopping mekanizmalarını kullanarak stabil öğrenme sağladım; Mixed Precision Training (AMP) desteğiyle hız ve GPU bellek verimliliğini artırdım.
- Model performansını Exact Match (EM), F1 Score ve answerability classification (cevaplanabilirlik sınıflandırması) doğruluğu metrikleri üzerinden değerlendirdim ve yanlış tahminleri loglayarak detaylı hata analizi gerçekleştirdim.

NLI (Natural Language Inference) Classification

Kullanılan Teknolojiler: Python, PyTorch, DeBERTa-v3, SBERT, NLI, Transformer, NLP

- SNLI ve MNLI veri setlerini kullanarak metinler arası çıkarım ilişkisini (entailment, neutral, contradiction) tespit eden bir sınıflandırma modeli geliştirdim.
- Transformer tabanlı encoder (DeBERTa-v3) ile "premise-hypothesis" metin çiftlerini işledim ve her iki metin bileşeni için "Classwise Attention Pooling" yöntemiyle dikkat ağırlıklı temsiller çıkardım.
- Aynı metin örnekleri için SBERT ile önceden çıkarılmış vektör temsillerini modele ek girdi olarak entegre ettim.
- Eğitim sırasında Contrastive Loss ve Semantic Similarity Regression (Cosine Similarity + MSE) fonksiyonlarını birlikte optimize ederek çok bileşenli bir mimari kurdum.
- Proje sonucunda hem klasik sınıflandırma doğruluğunu hem de anlamsal tutarlılığı aynı anda maksimize eden hibrit bir öğrenme sistemi ortaya koydum.

Türkçe Metin Özetleme Sistemi (umT5 Tabanlı)

Kullanılan Teknolojiler: Python, PyTorch, Transformers, umT5, ROUGE, NLP, Seq2Seq, Türkçe Veri İşleme

- umT5 mimarisini temel alarak, Türkçe metinlerden bilgi yoğun ve yapısal olarak anlamlı özetler üreten bir Seq2Seq modeli geliştirdim.
- Önceden eğitilmiş umT5 modelini, Türkçe haber başlık-özet çiftleriyle fine-tune (ince ayar) ederek özetleme görevine adapte ettim.
- Model eğitim sürecini PyTorch tabanlı olarak sıfırdan kodladım; AMP (Mixed Precision), Early Stopping ve Scheduler mekanizmalarını entegre ettim.
- Eğitim sırasında optimizasyon için LookAhead algoritmasını kullanarak daha net performans artışı elde ettim ve model eğitimini stabilize ettim.
- Veri ön işleme aşamasında cümle temizleme, uzunluk filtreleme ve tokenizer uyumluluğu süreçlerini tamamladım; çıktı kalitesini ROUGE-1, ROUGE-L, ROUGE-2 ve METEOR skorları üzerinden değerlendirerek başarılı bir Türkçe özetleme performansı sağladım.

Fashion Product Multi-Task Classification System

Kullanılan Teknolojiler: Python, PyTorch, Computer Vision, Multi-Task Learning, ResNet-50

- Moda ürünlerinin sezon, yıl, kullanım amacı ve giyim türü sınıflarını tek bir girdi üzerinden aynı anda tahmin edebilen çok görevli (Multi-Task) bir CNN modeli geliştirdim.
- Önceden eğitilmiş ResNet-50 ağını kullanarak ürün görsellerinden derin özellik temsilleri (feature extraction) çıkardım; dört farklı görev için ortak bir feature extractor ve her göreve özel tam bağlantılı sınıflandırıcı başlıklar (heads) tasarladım.
- Multi-Task Learning yaklaşımıyla görevler arası bilgi paylaşımını sağlayarak genel doğruluğu maksimize ettim ve Cross-Entropy Loss ile görev bazlı ağırlıklandırma yaptım.
- Veri artırma (rotation, horizontal flip, brightness shift) yöntemleri uygulayarak modelin genellenebilirliğini artırdım ve Early Stopping mekanizması ile overfitting'i (aşırı öğrenme) minimize ettim.
- Model mimarisini PyTorch ile uçtan uca tasarlayıp eğittim; performansı Accuracy ve Macro-F1 metrikleri üzerinden değerlendirdim.

EfficientNet-B4 Flower Classification (Progressive Training)

Kullanılan Teknolojiler: Python, PyTorch, EfficientNet-B4, Progressive Learning, Custom Head, MixUp/CutMix

- Oxford Flowers-102 veri setini kullanarak 102 farklı çiçek türünü sınıflandıran, EfficientNet-B4 omurgası (backbone) üzerine kurulu yüksek başarımlı (SOTA) bir derin öğrenme modeli geliştirdim.
- Sınıflandırma katmanını, özellik çıkarımını maksimize eden BatchNorm, Dropout, Linear ve GELU aktivasyon fonksiyonlarını içeren özelleştirilmiş bir başlık (Custom Classifier Head) ile yeniden tasarladım.
- Öğrenme sürecini stabilize etmek amacıyla 6 Aşamalı Progresif Eğitim stratejisi kurguladım; görüntü çözünürlüğünü 280px'den başlatıp kademeli olarak artırarak final aşamasında 400px'e yükselttim.
- Modelin dayanıklılığını (robustness) artırmak için eğitim fazlarına sırasıyla Temel Öğrenim, MixUp (Doku Karıştırma), CutMix (Nesne Tamamlama) ve Hibrit (MixUp + CutMix) veri artırma tekniklerini entegre ettim.
- Veri besleme hattında (Pipeline), 8 adımlı Image-Level Preprocessing ve faza özgü Batch-Level Augmentation tekniklerini birleştiren çift katmanlı bir veri işleme stratejisi uyguladım.
- Overfitting ve underfitting sinyallerine anlık tepki veren "Smart Dropout" mekanizmasını ve faz geçişlerini kontrol eden katmanlı Early Stopping sistemini entegre ettim; test setinde %94.49 Top-1 ve %98.49 Top-5 doğruluk oranlarına ulaştım.

Stacking & Meta-Stacking DistilBERT Vektörleri ile Karşılaştırılması

Kullanılan Teknolojiler: Python, Scikit-learn, NLP, TF-IDF, ML, DL, DistilBERT, Ensemble Learning

- Metin verilerini DistilBERT modeli kullanarak 768 boyutlu sabit vektör temsillerine dönüştürerek makine öğrenmesi algoritmaları için giriş verisi hazırladım.
- Çeşitli makine öğrenmesi modellerini (KNN, Logistic Regression, Naive Bayes, Decision Tree, SVM, ANN) uçtan uca eğiterek temel sınıflandırma performanslarını test ettim.
- Modellerin zayıf yönlerini dengelemek ve tahmin başarısını artırmak amacıyla farklı baz modellere (KNN, Decision Tree, SVM vb.) sahip üç ayrı Stacking modeli tasarladım ve Final Estimator olarak Logistic Regression, Random Forest ve Gradient Boosting kullandım.
- Ensembles modellerin çıktılarını birleştiren kapsamlı bir Meta-Stacking mimarisi (SVM + Stacking 2 + Stacking 3) kurguladım ve tüm mimarilerin başarısını 5-Fold Cross-Validation (Çapraz Doğrulama) yöntemiyle güvenilir bir şekilde değerlendirdim.